Brayan Ricardo Pisso Ramirez

Solución Taller TAM #1

1. Clasificación lineal y algoritmo del perceptrón

Considere un clasificador binario para observaciones $x \in \mathbb{R}^2$, con etiquetas $y \in \{-1, +1\}$, cuya predicción se obtiene mediante

$$\hat{y} = \begin{cases} +1, & w^T x + b > 0, \\ -1, & w^T x + b \leq 0, \end{cases} \qquad w \in \mathbb{R}^2, \quad b \in \mathbb{R}$$

1.1. Frontera de decisión: Sea $w = [1, 2]^T$ y $b = -3$. Obtenga la ecuación de la recta $w^T x + b = 0$, dibújela e indique la clase asignada a $x_1 = (0,0)$, $x_2 = (1,0)$, $x_3 = (2,1)$ y $x_4 = (3,1)$. Justifique cada predicción

Ecuación de la frontera de decisión

$$1 \cdot x_1 + 2 \cdot x_2 - 3 = 0 \Rightarrow 2x_2 = -x_1 + 3 \Rightarrow x_2 = -\frac{1}{2} x_1 + \frac{3}{2}$$

la recta intersecta el eje x_2 en el punto $(0, 1.5)$ y el eje x_1 en $(3,0)$

Evaluación y clasificación de las observaciones:

Para $x_1 = (0,0)^T$

$$w^T x_1 + b = 1(0) + 2(0) - 3 = -3 \leq 0 \Rightarrow \hat{y}_1 = -1$$

Para $x_2 = (1,0)^T$

$$w^T x_2 + b = 1(1) + 2(0) - 3 = -2 \leq 0 \Rightarrow \hat{y}_2 = -1$$

Para $x_3 = (2,1)^T$

$$w^T x_3 + b = 1(2) + 2(1) - 3 = 1 > 0 \Rightarrow \hat{y}_3 = 1$$

Para $x_4 = (3,1)^T$

$$w^T x_4 + b = 1(3) + 2(1) - 3 = 2 > 0 \Rightarrow \hat{y}_4 = 1$$

Primavera

Scanned with CamScanner

Justificación: Las observaciones x_1 y x_2 se ubican en el semiplano cerrado definido por $w^T x + b \leq 0$, asignándoles la clase -1. Por su parte, x_3 y x_4 caen en el semiplano abierto $w^T x + b > 0$, asignándoles la clase $+1$.

1-2 Actualización de perceptrón. Cuando una observación (x_i, y_i) está mal clasificada, considere la regla

$$w_{nuevo} = w + \eta y_i x_i, \qquad b_{nuevo} = b + \eta y_i, \quad \eta > 0$$

Defina el margen de la observación como $m_i = y_i (w^T x_i + b)$ y demuestre que, inmediatamente después de aplicar la actualización sobre esa misma observación

$$m_{i,\,nuevo} = m_i + \eta \left(\|x_i\|_2^2 + 1 \right)$$

Explique brevemente qué implica este resultado para la observación corregida.

Cuando una observación (x_i, y_i) está mal clasificada, la regla de actualización es

$$w_{nuevo} = w + \eta y_i x_i, \qquad b_{nuevo} = b + \eta y_i \quad (\text{con } \eta > 0)$$

Definiendo el margen funcional como $m_i = y_i (w^T x_i + b)$, evaluamos el nuevo margen $m_{i,nuevo}$ inmediatamente después de la actualización

$$\begin{aligned} m_{i,nuevo} &= y_i \left(w_{nuevo}^T x_i + b_{nuevo} \right) \\ &= y_i \left((w + \eta y_i x_i)^T x_i + (b + \eta y_i) \right) \\ &= y_i \left(w^T x_i + \eta y_i (x_i^T x_i) + b + \eta y_i \right) \\ &= y_i \left((w^T x_i + b) + \eta y_i \left(\|x_i\|_2^2 + 1 \right) \right) \\ &= y_i (w^T x_i + b) + \eta y_i^2 \left(\|x_i\|_2^2 + 1 \right) \end{aligned}$$

Primavera

Scanned with CamScanner

Como la etiqueta satisface $y_i \in \{-1, +1\}$, tenemos obligatoriamente $y_i^2 = 1$. Sustituyendo m_i:

$$m_{i,\text{nuevo}} = m_i + \eta\left(\|x_i\|_2^2 + 1\right)$$

Implicación práctica:

Dado que la tasa de aprendizaje $\eta > 0$ y el término $(\|x_i\|_2^2 + 1) \geq 1 > 0$, la constante $\eta(\|x_i\|_2^2 + 1)$ es estrictamente positiva. Esto garantiza que el margen de la observación corregida aumenta (cuando falla) estrictamente ($m_{i,\text{nuevo}} > m_i$), desplazando y rotando el hiperplano en la dirección adecuada para corregir el error de clasificación sobre dicha muestra.

1.3 Ejercicio numérico. Con $w = [0, 0]^T$, $b = 0$, $\eta = 0{,}5$, $x = [2, 1]^T$ y $y = +1$, determine si corresponde actualizar los parámetros usando la regla de predicción dada. De ser así, calcule los pesos nuevos, el bias y margen.

Datos iniciales: $w = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $b = 0$, $\eta = 0{,}5$, $x = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, $y = +1$

Evaluación de la predicción inicial

$$w^T x + b = 0(2) + 0(1) + 0 = 0$$

Aplicando la regla del enunciado ($\hat{y} = -1$ si $w^T x + b \leq 0$) el modelo predice $\hat{y} = -1$. Como la etiqueta real es $y = +1$, el punto está mal clasificado ($y \neq \hat{y}$). Por lo tanto, SÍ corresponde actualizar los parámetros.

Cálculo de los nuevos parámetros

$$w_{\text{nuevo}} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0.5(+1)\begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 10 \\ 5 \end{bmatrix}$$

$$b_{\text{nuevo}} = 0 + 0{,}5(+1) = 0{,}5$$

Primavera

Scanned with CamScanner

Cálculo del nuevo margen

$$m_{nuevo} = y(w_{nuevo}^T x + b_{nuevo}) = 1 \cdot (1{,}0(2) + 0{,}5(1) + 0{,}5) = 1(2 + 0{,}5 + 0{,}5) = 3$$

Verificando mediante la fórmula demostrada en 1.2:

$m_{original} = 1(0) = 0, \quad \|x\|_2^2 = 2^2 + 1^2 = 5$

$m_{nuevo} = 0 + 0{,}5(5+1) = 0{,}5(6) = 3$

2. Clasificación por los K vecinos más cercanos (K-NN)

Considere una observación nueva $q = (1,1)$ y el siguiente conjunto de entrenamiento

Observaciones	x_1	x_2	x_3	x_4	x_5
x_i	(0,0)	(1,0)	(3,1)	(0,3)	(1.1, 1.1)
Clase	A	A	B	B	B

Use la distancia euclidiana $d(q, x_i) = \sqrt{(q_1 - x_{i,1})^2 + (q_2 - x_{i,2})^2}$ y la votación mayoritaria de los K vecinos más próximos.

2.1 Cálculo manual. Calcule las cinco distancias y ordene las observaciones desde la más cercana hasta la más lejana. Clasifique q utilizando K=1, K=3, y K=5. Explique por qué el valor de K puede cambiar la predicción.

Instancia de consulta $q = (1,1)$. Conjunto de entrenamiento: $x_1 = (0,0)$ [A], $x_2 = (1,0)$ [A], $x_3 = (3,1)$ [B], $x_4 = (0,3)$ [B], $x_5 = (1.1, 1.1)$ [B]

Cálculo de distancias euclidianas $d(q, x_i) = \sqrt{(q_1 - x_{i,1})^2 + (q_2 - x_{i,2})^2}$:

1. $d(q, x_5) = \sqrt{(1 - 1.1)^2 + (1 - 1.1)^2} = \sqrt{(-0{,}1)^2 + (-0{,}1)^2} = \sqrt{0{,}02} \approx 0{,}1414$ (clase B)

2. $d(q, x_2) = \sqrt{(1-1)^2 + (1-0)^2} = \sqrt{0+1} = \sqrt{1} = 1.0000$ (Clase A)

3. $d(q, x_1) = \sqrt{(1-0)^2 + (1-0)^2} = \sqrt{1+1} = \sqrt{2} \approx 1.4142$ (Clase A)

4. $d(q, x_3) = \sqrt{(1-3)^2 + (1-1)^2} = \sqrt{(-2)^2 + 0} = \sqrt{4} = 2.0000$ (Clase B)

5. $d(q, x_4) = \sqrt{(1-0)^2 + (1-3)^2} = \sqrt{1 + (-2)^2} = \sqrt{5} \approx 2.2361$ (Clase B)

Ordenamiento de menor a mayor distancia:

x_5 ($d = 0,1414$, B) $<$ x_2 ($d = 1,0000$, A) $<$ x_1 ($d = 1,4142$, A) $<$ x_3 ($d = 2,0000$, B) $<$ x_4 ($d = 2,2361$, B)

Votación mayoritaria y predicción según K:

- Para $K=1$: Conjunto de vecinos $\{x_5\}$. Votos: B = 1, A = 0 ⇒ Clase B
- Para $K=3$: Conjunto de vecinos $\{x_5, x_2, x_1\}$. Votos: A = 2, B = 1 ⇒ Clase A
- Para $K=5$: Conjunto de vecinos $\{x_5, x_2, x_1, x_3, x_4\}$. Votos: B = 3, A = 2 ⇒ Clase B

Explicación del cambio: El valor de K actúa como un regulador de la escala de suavizado de la frontera. Con $K=1$, la regla es estrictamente local y responde al punto extremadamente cercano x_5. Con $K=3$, la ventana se amplía incorporando el grupo local de la Clase A (x_1, x_2). Con $K=5$, el modelo toma en cuenta la totalidad de la muestra, donde la clase B constituye la mayoría global.

2.2. Genere N=300 observaciones bidimensionales con la función make_moons, usando noise = 0.20 y random_state = 42. Separe 70% para entrenamiento y 30% para prueba, estratificando las clases. Entrene KNeighborsClassifier con $k \in \{1, 5, 15\}$. Reporte exactitud (accuracy) en entrenamiento y prueba para cada caso. Debuje los datos y, al menos para K=1 y K=15, sus regiones de decisión.

Primavera

Scanned with CamScanner

2.3. Descarta qué errores al escoger una K muy pequeño o muy grande. Indique cuál de los modelos generalizo mejor en esta evaluación y justifique su elección. Explique por qué la selección formal del mejor K debe realizarse con validación, no con los datos de prueba.

Interpretación y decisión

K muy pequeño (K=1): El modelo presenta baja varianza y alto sobreajuste (overfitting). Memoriza perfectamente el ruido del conjunto de entrenamiento (100% accuracy en train), creando fronteras de decisión extremadamente complejas e irregulares.

K muy grande (K=15): El modelo incrementa su sesgo y suaviza en exceso la frontera, lo que puede resultar en subajuste (underfitting), perdiendo la estructura fina o local de las "lunas".

Mejor modelo K=5: logró el mejor equilibrio (trade-off-sesgo-varianza) alcanzando la máxima exactitud en el conjunto de prueba (95.56%).

Selección formal de hiperparámetros K: La selección debe realizarse obligatoriamente mediante validación cruzada (K-fold-cross-validation) dentro del conjunto de entrenamiento. Usar directamente los datos de prueba para elegir K produce fuga de información (data leakage), invalidando el conjunto de prueba como estimador insesgado del error de generalización.

3. Evaluación de un clasificador binario

Sea un conjunto de diez etiquetas verdaderas y y sus predicciones $\hat{y}$:

$$y=[0,0,0,0,1,1,1,1,1,1],\quad \hat{y}=[0,1,0,0,1,0,1,1,0,1]$$

Tome la clase 1 como positiva. Recuerde que TP y TN representan aciertos positivos y negativos, mientras que FP y FN son los errores correspondientes

Primavera

Scanned with CamScanner

3.1. Matriz de confusión. Construya la matriz de confusión con filas correspondientes a clases reales y columnas a clases predichas. Identifique TP, TN, FP, y FN.

Dada las etiquetas reales "y" y las predicciones "$\hat{y}$" contra posición por posición (tomando clase 1 como positiva y 0 como negativa):

Verdaderos positivos (TP): $y=1$, $\hat{y}=1$ ⇒ Posiciones 5, 7, 8, 10 ⇒ TP = 4

Verdaderos Negativos (TN): $y=0$, $\hat{y}=0$ ⇒ Posiciones 1, 3, 4 ⇒ TN = 3

Falsos Positivos (FP): $y=0$, $\hat{y}=1$ ⇒ Posición 2 ⇒ FP = 1

Falsos Negativos (FN): $y=1$, $\hat{y}=0$ ⇒ Posiciones 6, 9 ⇒ FN = 2

3.2. Métricas. Calcule manualmente las siguientes medidas y explique qué evalúa cada una

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}, \quad \text{Precisión} = \frac{TP}{TP+FP}$$

$$\text{Recall} = \frac{TP}{TP+FN}, \quad F_1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision}+\text{Recall}}$$

1. Accuracy

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{4+3}{4+3+1+2} = \frac{7}{10} = 0{,}7000\ (70\%)$$

Significado: Proporción global de predicciones correctas (tanto positivas como negativas) sobre el total de casos.

2. Precisión

$$\text{Precisión} = \frac{TP}{TP+FP} = \frac{4}{4+1} = \frac{4}{5} = 0{,}8\ (80\%)$$

Significado = Porcentaje de acierto cuando el modelo predice la clase positiva (fiabilidad de las alarmas positivas)

Primavera

Scanned with CamScanner

3. Recall

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{4}{4+2} = \frac{4}{6} = 0,6667 \ (66\%)$$

Significado: capacidad del modelo para detectar y capturar los casos reales pertenecientes a la clase positiva.

4. F1 - Score

$$F_1 = 2\left(\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}\right) = 2\left(\frac{0,80\,(2/3)}{0,80 + (2/3)}\right) = \frac{1,0667}{1,4667} = 0,7273 \ (72,73\%)$$

Significado: Media armónica entre precisión y recall, proporcionando un balance adecuado entre ambas métricas.

3.3 Verificación y análisis. En Python, comprueba sus resultados usando las funciones confusion_matrix y accuracy_scores, además con precision_score, recall_score y f1_score. Escriba dos situaciones en las que la exactitud por sí sola podría resultar engañosa.

1er situación: Conjunto de datos altamente desbalanceado: En escenarios como detección de fraude bancario o diagnóstico de enfermedades raras (donde el 99% de los datos pertenecen a la clase negativa), un clasificador ingenuo que prediga siempre la clase negativa obtendrá un Accuracy del 99%. Sin embargo, este modelo es completamente inútil ya que su Recall sobre la clase de interés es 0.

2da situación: Costos asimétricos entre falsos positivos y falsos negativos: En diagnósticos médicos graves, cometer un falso Negativo (no detectar a un paciente enfermo) puede ser fatal, mientras que un falso positivo requiere un examen de verificación. El accuracy trata a ambos tipos de error con idéntico peso, ocultando el riesgo operacional real del modelo.

Primavera

Scanned with CamScanner